

Trabalho para Avaliação da Disciplina (A2)

1. Introdução

Desafios em Ciência de Dados referem-se a problemas complexos e intrincados que os profissionais dessa área enfrentam ao lidar com dados, desde a coleta até a análise e interpretação. Esses desafios podem envolver uma variedade de aspectos, entre os quais podemos destacar:

1. **Qualidade dos Dados:** Muitas vezes, os dados disponíveis não são limpos, consistentes ou completos. Tratar com dados de baixa qualidade pode ser um desafio significativo.
2. **Volume de Dados:** Com o aumento exponencial da quantidade de dados gerados diariamente, lidar eficientemente com grandes volumes de dados é um desafio constante.
3. **Variedade de Dados:** A diversidade de formatos e tipos de dados (textos, imagens, vídeos, etc.) pode tornar difícil a integração e análise unificada.
4. **Velocidade de Processamento:** Em alguns casos, é crucial analisar e obter *insights* em tempo real, o que impõe desafios significativos em termos de velocidade de processamento.
5. **Segurança e Privacidade:** A manipulação de dados sensíveis exige precauções rigorosas para garantir a segurança e a privacidade das informações.
6. **Interpretabilidade e Explicabilidade:** Em muitos casos, os modelos de *machine learning* são caixas-pretas, o que significa que entender como e por que uma decisão foi tomada pode ser desafiador.
7. **Escolha de Modelos:** A seleção do modelo adequado para um determinado problema é um desafio, pois diferentes modelos têm suas próprias vantagens e limitações.
8. **Validação e Avaliação de Modelos:** Determinar a eficácia de um modelo e garantir que ele generalize bem para dados não vistos são desafios críticos.
9. **Integração de Resultados na Tomada de Decisão:** Tornar os resultados da análise de dados acessíveis e úteis para a tomada de decisão nas organizações é um desafio adicional.
10. **Manutenção e Atualização:** Modelos de *machine learning* precisam ser mantidos e atualizados ao longo do tempo para garantir que permaneçam eficazes e alinhados com as mudanças nos dados e nos requisitos do negócio.

Lidar com esses desafios requer uma combinação de habilidades técnicas, conhecimento de domínio e uma abordagem metodológica sólida para a resolução de problemas em Ciência de Dados.

2. Contextualização do desafio

O conjunto de dados permite várias novas combinações de atributos e exclusões de atributos, ou a modificação do tipo de atributo (categórico, inteiro ou real), dependendo do objetivo da pesquisa. O conjunto de dados (Absentismo no trabalho) contém registros de funcionários, horas de ausência, motivos e categorias que permitem uma limpeza profunda.

3. Desenvolvimento do trabalho

O presente trabalho tem como objetivo investigar os determinantes do absenteísmo e compreender como inconsistências em dados brutos podem mascarar padrões críticos de comportamento organizacional. Através da base, buscaremos mitigar ruídos estatísticos — como dados faltantes e valores atípicos — que impedem uma visão clara sobre a produtividade. A metodologia segue o fluxo analítico fundamental: Análise Exploratória (EDA), Tratamento de Dados (Data Cleaning) e Comunicação Visual.

Parte 1: Captação e avaliação dos tipos de dados

1. Extrair os dados de `"cas-shared-default/ACADEMIC/ABSENTEEISM"` ;
2. Dicionário de dados;

Parte 2: Análise Exploratória.

Após a captação, os dados são importados para o ambiente desejado para a execução da Análise Exploratória (EDA). Esta fase busca apresentar o cenário real da empresa antes de qualquer processo de limpeza, evidenciando a necessidade crítica do tratamento de dados. Para isso, são utilizadas medidas de tendência central e dispersão, além de ferramentas visuais como histogramas e boxplots, que permitem visualizar a distribuição das ausências e identificar visualmente os pontos fora da curva. O objetivo é desenvolver painéis de informações que ofereçam um retrato fiel do período analisado, demonstrando como os ruídos estatísticos e as inconsistências da base bruta podem mascarar os verdadeiros motivos do absenteísmo na organização.

Parte 3: Tratamento de Dados.

Com o diagnóstico em mãos, o trabalho avança para a fase de Tratamento de Dados, onde são aplicadas técnicas rigorosas de higienização. Nesta etapa, as duplicatas são removidas e os valores faltantes são tratados por meio de métodos de imputação estratégica, como a substituição pela média ou mediana, garantindo que a base não perca volume crítico de informações. Os outliers identificados anteriormente são endereçados através de técnicas de exclusão ou suavização, evitando que casos extremos distorçam as métricas de desempenho.

Além disso, realiza-se a padronização das variáveis e a correção de tipos, transformando a base bruta em um conjunto de dados íntegro e pronto para a modelagem.

Parte 4: Comunicação Visual.

Esta seção foca no storytelling, traduzindo números complexos em narrativas visuais claras que apontam as principais causas do absenteísmo. O resultado é uma apresentação robusta que não apenas exibe dados limpos, mas fundamenta recomendações estratégicas.

4. Produtos para entrega:

- Relatório contendo a documentação do desenvolvimento. Interpretar os resultados. Não colocar código.
- Este trabalho deverá estar concluído até o dia **16 de abril de 2026**.

Ótimo trabalho a todos.